

Plan analítico para arrestos y seguridad vial en Nueva York

Primera entrega del proyecto de Big Data | Entendimiento del negocio y de los datos

Fecha de corte: 30 de septiembre de 2026. Entrega: 2 de octubre de 2026.

Resumen ejecutivo

El encargo busca orientar decisiones públicas sobre arrestos y siniestros viales en la ciudad de Nueva York. Esta primera entrega define las preguntas, revisa cuatro conjuntos de datos obligatorios, identifica sus límites y entrega una exploración reproducible en PySpark. Aún no hay evidencia suficiente para atribuir causas ni recomendar un despliegue territorial definitivo. La prioridad inmediata es construir series comparables de arrestos y colisiones, con denominadores y geografía verificables.

El conjunto de vehículos registra vehículos involucrados; contar sus filas sobrestima colisiones cuando intervienen varios vehículos. El conjunto de pobreza de 2018 se ubica a nivel de persona y exige pesos y diccionario para tasas poblacionales. El SAT de 2012 se ubica a nivel de escuela; el reporte SAT 2024 describe el estado de Nueva York y usa otra escala, población y periodo. Estas distinciones determinan qué cruces son defendibles.

Decisión solicitada al equipo de gobierno

Autorizar una segunda fase de validación de datos completos y diseño de intervenciones piloto. La selección de zonas debe esperar un tablero con la fuente de colisiones por siniestro, población o exposición adecuada, periodos comparables, y revisión de equidad y privacidad.

Qué contiene la entrega

Informe de al menos ocho páginas con fuentes y criterios de decisión; notebook PySpark con diez bloques exploratorios, reglas de calidad y transformaciones; presentación ejecutiva de 15 minutos. Los resultados observados se etiquetan como hechos de fuente o del extracto. Las medidas futuras se señalan como propuestas.

Al 30 de septiembre de 2026, el equipo sí puede sostener la selección de fuentes, las diferencias entre sus unidades y diagnósticos de extractos que acompañan la entrega. Aún no puede sostener una cifra nueva de accidentes de la ciudad, una tasa de arrestos por población ni una asociación entre pobreza, SAT y seguridad. Esta distinción separa lo que el gobierno puede decidir ahora —financiar la integración y evaluación— de lo que requiere una etapa adicional de evidencia.

1. Entendimiento del negocio

El problema se plantea para el gobierno del estado de Nueva York, pero las fuentes de arrestos y movilidad suministradas son de la ciudad de Nueva York. Por ello, la unidad operativa de esta entrega es la ciudad. Cualquier extrapolación al estado requeriría otras fuentes. El objetivo de negocio es reducir los daños asociados con siniestros viales y mejorar la gestión de arrestos mediante decisiones territoriales basadas en datos. Una caída de arrestos, por sí sola, no demuestra menor criminalidad: también puede reflejar cambios de patrullaje, aplicación de la ley o registro.

Como contexto macroeconómico, la ciudad registró 8 804 190 residentes en el Censo de 2020. QuickFacts del Census Bureau informa ingreso mediano de hogares de USD 80 483 en dólares de 2024 para 2020–2024 y 17,9 % de personas en pobreza según su medida federal. El Departamento de Trabajo estatal publicó una tasa de desempleo desestacionalizada de 4,8 % para la ciudad en agosto de 2026. Son indicadores de contexto, con calendarios y definiciones distintas; ninguno explica causalmente los arrestos o siniestros.

El éxito futuro debe medirse con resultados y exposición: colisiones por periodo y lugar, lesiones graves y muertes cuando se incorpore la tabla de siniestros; arrestos por periodo y jurisdicción con control de cambios en registro y actividad policial. Los indicadores deben desagregarse con suficiente tamaño para proteger privacidad y evitar interpretaciones espurias. El gobierno puede usar análisis descriptivo para priorizar revisión de infraestructura vial, horarios y servicios preventivos, seguido de pilotos evaluados.

Preguntas de negocio

¿En qué periodos y zonas se concentran los registros de arresto? ¿Qué tipos de vehículos y factores se reportan en colisiones? ¿Qué intervenciones viales caben en zonas de mayor riesgo una vez incluidos siniestros y exposición? ¿Cómo cambia una prioridad territorial al considerar contexto social sin convertir pobreza o educación en sustitutos de riesgo individual?

La unidad territorial también importa. Un borough permite un primer resumen, pero puede ocultar diferencias entre barrios y vías. Un precinct describe jurisdicción policial y no equivale a una zona vial ni a un distrito escolar. Para decisiones de calle, el equipo necesitará geocodificación validada y una unidad de agregación estable. Debe evitar mapas de puntos de arresto o colisión que revelen ubicaciones sensibles y pueden magnificar diferencias de registro.

2. Selección de fuentes y pertinencia

Fuente	Unidad y periodo	Uso defendible
NYPD Arrest Data Year to Date, uip8-fykc	Arresto; actualización durante el año	Describir fechas, categorías y borough del registro.
NYCgov Poverty Measure Data 2018, cts7-vksw	Persona; 2018	Contexto socioeconómico con definiciones y pesos.
Motor Vehicle Collisions Vehicles, bm4k-52h4	Vehículo participante; serie histórica	Explorar factores, tipo de vehículo y agrupar por collision_id.
2012 SAT Results, f9bf-2cp4	Escuela; 2012	Antecedente educativo, sin comparación directa con 2024.
SAT Suite Report New York 2024	Estado y cohorte de 2024; PDF	Contexto reciente, no microdatos escolares de NYC.

Se usan los cuatro enlaces de datos suministrados, contando como cuarto el reporte educativo de 2012 y tratando el PDF 2024 como actualización contextual. Los metadatos oficiales se guardaron junto con extractos reproducibles. La fecha exacta de extracción y los recuentos del API constan en el manifiesto; un recuento del API puede cambiar después del corte.

Para el indicador de accidentes, la tabla obligatoria de vehículos no contiene por sí sola todos los atributos del siniestro ni la localización que exige la decisión territorial. Se propone complementar con Motor Vehicle Collisions – Crashes, que relaciona collision_id con un evento. No forma parte de los cuatro extractos analizados aquí. El total de filas de vehículos nunca debe presentarse como cantidad de accidentes.

La fuente SAT 2012 puede contener celdas suprimidas o no numéricas, y su lectura requiere conversión controlada. El informe 2024 del College Board reporta 127 993 participantes SAT de la cohorte de graduados y una participación de 61 % en el estado. El propio informe advierte que la participación y composición afectan comparaciones, y que no reemplaza las estadísticas oficiales estatales de exámenes. Estos valores no describen exclusivamente la ciudad.

La pertinencia se evaluó con cinco criterios: relación con la pregunta, unidad de observación, cobertura temporal, cobertura geográfica y posibilidad de enlazar mediante una clave legítima. Arrestos responde directamente al primer indicador. Vehicles contribuye a describir circunstancias de movilidad, pero necesita Crashes para el segundo. Pobreza y SAT contextualizan condiciones sociales; no se incorporan como predictores de riesgo individual ni se usan para explicar retrospectivamente eventos de 2026. Cada fuente mantiene su definición y sus limitaciones en el catálogo.

3. Preguntas analíticas y criterios de éxito

La primera fase es descriptiva. El análisis debe producir un inventario de campos, calidad, cobertura, unidades y posibilidades de integración. Un resultado de esta fase es “apto” solo si especifica numerador, denominador, periodo, geografía y calidad de la fuente. La meta no es predecir personas que serán arrestadas ni clasificar escuelas como causantes de seguridad pública.

Pregunta	Indicador / comprobación	Decisión asociada
Concentración de arrestos	Recuento distinto de arrest_key por mes y borough; cobertura y nulos	Definir dónde revisar procesos y servicios.
Concentración de siniestros	Recuento distinto de collision_id; validar con Crashes	Seleccionar zonas para auditoría vial.
Composición de vehículos	Distribución de tipos y factores reportados	Diseñar hipótesis de prevención vial.
Desigualdad territorial	Pobreza ponderada y educación con calendarios compatibles	Revisar equidad, sin inferir causalidad individual.

Para una fase posterior, el criterio de evaluación de pilotos debe predefinirse antes de intervenir: comparación de periodos equivalentes, grupos territoriales comparables, indicador de lesiones o daños, y seguimiento de cambios en exposición. Una reducción aparente del número de registros sin control de cambios administrativos no basta. La priorización tendrá revisión humana y una justificación pública de criterios.

Hipótesis, no resultados

Podrían existir horarios con concentración de colisiones vinculadas a ciertas maniobras o tipos de vehículo. Podrían variar los patrones de arresto entre boroughs. También podría haber correlaciones territoriales entre condiciones socioeconómicas e indicadores de seguridad. Ninguna de estas hipótesis se afirma como hallazgo mientras no se ejecute el análisis de población completa, se estandaricen calendarios y se controlen exposiciones.

La fórmula base de un conteo mensual de arrestos es el número de claves arrest_key distintas con fecha dentro del mes y geografía válida. Para colisiones, el numerador es el número de collision_id distintos en Crashes con la misma ventana. Una tasa necesita un denominador acorde: residentes puede servir para algunas preguntas sobre arrestos; viajes o flujo vial puede ser más relevante para riesgo de tránsito. No se escogerá el denominador por disponibilidad solamente. El periodo de comparación deberá mantener igual definición y considerar estacionalidad.

4. Arquitectura y preparación de datos

El cuaderno lee archivos JSON Lines en PySpark y conserva el extracto original. Una capa de preparación convierte fechas, normaliza el código de borough y crea banderas de validez. Las deduplicaciones siguen claves coherentes con cada unidad: `arrest_key` para arrestos, `unique_id` para vehículo, `serialno` más `sporder` para persona y `dbn` para escuela. `collision_id` se utiliza para agrupar vehículos por siniestro, pero no es clave única de la tabla de vehículos.

Las transformaciones propuestas no imputan fecha, lugar, identidad ni puntajes. Una fila sin clave o fecha necesaria para una serie se marca inválida y se reporta aparte. Para SAT 2012 solo se convierten a número cadenas con formato numérico; los valores suprimidos se conservan como nulos analíticos. La tasa de pobreza exige comprobar los códigos de `nycgov_pov_stat`, la población cubierta y el uso de `pwgtp` antes de calcularse. Los pesos pueden cambiar el resultado respecto al conteo simple.

Plan de integración

Arrestos tiene `arrest_boro` y `precinct`; vehículos registra `collision_id` y fecha, pero en el extracto de vehículos enlazado no hay borough. Por ello, el cruce territorial exige unir con la tabla de siniestros mediante `collision_id`. La pobreza cuenta con boro codificado y el SAT escolar con DBN, pero sus calendarios de 2018 y 2012 no coinciden con datos Year to Date. Se evitará una unión fila a fila. Un cruce futuro agregará cada fuente al mismo nivel territorial y periodo pertinente y documentará la pérdida de detalle.

Procesamiento distribuido

PySpark resulta apropiado para una eventual descarga completa por la escala potencial y por permitir transformaciones auditables. Este trabajo no atribuye cantidad de nodos, memoria, almacenamiento ni tiempos a un clúster institucional. La ejecución local de un extracto, cuando se realice, demuestra que el código funciona; no certifica capacidad para la población completa. El plan de despliegue requiere medir volumen real, tiempo y particionamiento en el entorno disponible.

El pipeline recomendado conserva una zona de datos crudos de solo lectura, una zona depurada con reglas versionadas y una tabla analítica por indicador. Cada corrida debe anotar URL, parámetros, fecha de corte, hash, versión del esquema, número de filas antes y después de cada regla y responsable del cambio. Cuando una columna cambie de tipo o desaparezca, el proceso debe detener la publicación automática y abrir una revisión. Esta trazabilidad permite repetir un resultado meses después aunque el portal público haya actualizado la vista.

5. Exploración de datos entregada

El notebook incluye diez bloques de exploración. Cada tabla que produce sobre los JSON Lines corresponde a un extracto de hasta 10 000 filas ordenado por identificador interno de Socrata; ese orden no es una muestra aleatoria. Por ello no se extrapolan porcentajes ni rankings. El manifiesto guarda el tamaño, SHA-256, enlace y momento de la consulta. Un recuento total del API, cuando responde, identifica el volumen de la vista en ese instante y no un indicador de política pública.

Bloque	Qué verifica
1. Esquema	Campos, tipos y registros ejemplo en las cuatro fuentes.
2. Tiempo	Fechas mínimas, máximas y nulas para arrestos y vehículos.
3. Claves	Nulos y unicidad; clave compuesta de persona.
4. Completitud	Nulos o vacíos por campo.
5. Categorías	Borough, tipo de vehículo, factor reportado y escuela.
6. Geografía	Distribución de arrestos por borough.
7. Tendencia	Recuentos por mes dentro del extracto.
8. Colisiones	Vehículos frente a collision_id distintos.
9. Pobreza	Códigos y distribución de pesos.
10. SAT	Celdas suprimidas y puntajes convertibles.

La exploración cumple un propósito de entendimiento. Las tablas de frecuencias pueden revelar anomalías de captura o cobertura, pero no permiten concluir que un borough sea más inseguro sin exposición, población, definición constante y archivos completos. Si algún archivo no se descargó o no hay PySpark en el entorno de evaluación, el notebook indicará el archivo faltante; se entregan los datos disponibles para ejecución autónoma.

Resultados reales del extracto: las 10 000 filas de arrestos cubren del 1 al 13 de enero de 2026; las 3 000 filas de vehículos contienen 2 999 identificadores de colisión distintos; las 478 escuelas de SAT 2012 incluyen 57 valores “s” en el campo de promedio de matemáticas. Estos datos son diagnósticos de cobertura y supresión, no estimaciones de indicadores de ciudad.

El orden de extracción por identificador interno es determinista y facilita repetir la lectura, pero selecciona registros tempranos de la vista. En arrestos el sesgo temporal es visible: trece días no representan el año. En vehículos, 2 999 collision_id para 3 000 filas solo describe cuántas colisiones aparecen en ese subconjunto y no demuestra que casi todos los siniestros tengan un solo vehículo. La supresión “s” impide calcular una media escolar incluyendo todos los centros; excluir esas celdas también puede sesgar una media agregada. Por ello el cuaderno presenta conteos de calidad y no un ranking.

6. Calidad, sesgos y privacidad

Las reglas de calidad del cuaderno cubren presencia de claves, fechas parseables, códigos de borough conocidos y pesos positivos. También se calcula completitud por columna y se observa la duplicación esperada de `collision_id` en una tabla de vehículos. Es importante diferenciar duplicados verdaderos de registros legítimos de dos vehículos para una misma colisión. Un chequeo de rango geográfico de coordenadas de arresto puede añadirse al pasar a datos completos; no se sustituye una latitud nula por el centro de un borough.

Los arrestos son eventos de actuación policial y dependen de despliegue, prioridades y denuncias. Su cantidad no mide de forma directa la incidencia delictiva. Los siniestros pueden tener rezagos de reporte; un registro de vehículo puede carecer de factores reportados. La medida de pobreza de NYC es distinta de la federal indicada por QuickFacts. El SAT puede reflejar participación selectiva y cambios de escala. Estos sesgos se documentan antes de cualquier correlación.

No se publicarán coordenadas precisas ni cruces de personas, vehículos y escuelas que permitan reidentificación. Los resultados de una presentación de gobierno deben agregarse a geografía y periodos apropiados; las celdas pequeñas se suprimen según la política que adopte el equipo público. Las variables demográficas de arrestados se usarán, si acaso, para auditoría de equidad, no para segmentar intervención punitiva.

Puertas de calidad antes de presentar hallazgos

Se exige verificar que la extracción sea completa y congelada; medir nulos de campos críticos; reconciliar el número de `collision_id` con la tabla Crashes; confirmar codificación y ponderación de pobreza; conservar el diccionario y la versión de cada fuente; y revisar comparabilidad de SAT. Cada transformación debe registrar filas de entrada, filas excluidas y motivo.

La revisión de equidad debe preguntar si el uso de un indicador perjudica de forma desproporcionada a grupos o zonas. Una zona con más arrestos podría recibir servicios o una auditoría de prácticas, pero una puntuación que dirija automáticamente más vigilancia reforzaría el mismo registro que alimenta el modelo. Los resultados SAT y de pobreza tampoco deben usarse para estigmatizar escuelas o residentes. La presentación pública debe explicar qué se mide y qué queda fuera, y permitir revisión de comunidades afectadas antes de implantar una intervención.

7. Plan de acción propuesto

Durante la siguiente fase, el equipo debe descargar las vistas completas con paginación o exportación oficial y guardar una instantánea fechada. Debe incorporar Motor Vehicle Collisions – Crashes para fechas, geografía y desenlaces. Tras los controles de calidad, generará series mensuales y mapas agregados por zona, acompañados de exposición (población, viajes o volumen vehicular, según la pregunta). Publicará definiciones de indicadores y la incertidumbre asociada.

Luego se seleccionarán pocas zonas piloto con base en indicadores de lesiones y siniestros, factibilidad de intervención y revisión local. Un posible piloto vial consiste en auditoría de cruces, señalización y velocidad con la autoridad competente; un posible piloto relacionado con arrestos consiste en revisar prácticas de registro y conectar zonas con servicios preventivos. Son opciones de política, no hallazgos del conjunto analizado. La evaluación debe acordar con las agencias la fecha de inicio, periodos de referencia y un grupo de comparación.

Cronograma orientativo, sujeto a recursos reales

Etapa	Producto verificable	Condición para avanzar
Integración	Extractos completos y catálogo de versiones	Cobertura y claves auditadas.
Diagnóstico	Series y geografía de indicadores	Denominadores y sesgos documentados.
Diseño de pilotos	Intervención y evaluación preregistrada	Aprobación operativa y de privacidad.
Seguimiento	Tablero y evaluación periódica	Revisión de efectos y equidad.

No se asignan semanas, costos ni capacidad de cómputo porque el caso no suministra personal, presupuesto ni infraestructura. La prioridad al 2 de octubre de 2026 es presentar el diseño, las fuentes y los riesgos de interpretación; la decisión de inversión vendrá con datos completos.

La evaluación de un piloto requiere una teoría de cambio concreta. Si se modifica un cruce, la hipótesis será que una reducción de conflictos de tráfico disminuye lesiones o siniestros, no solo que baja el volumen de reportes. Se deberá registrar la fecha de intervención, desvíos de circulación, obras simultáneas y cambios de vigilancia o denuncia. Una comparación antes y después puede servir como primera señal, pero una zona comparable mejora la interpretación. La decisión de ampliar el piloto debe atender a efectos no deseados y a distribución de beneficios.

8. Fuentes, trazabilidad y límites

Fuentes primarias consultadas: NYC Open Data, NYPD Arrest Data Year to Date (uip8-fykc); NYCgov Poverty Measure Data 2018 (cts7-vksw); Motor Vehicle Collisions Vehicles (bm4k-52h4); 2012 SAT Results (f9bf-2cp4). La consulta a los metadatos del API Socrata permitió identificar campos y unidades. Los enlaces y los archivos de metadatos quedan en la carpeta de datos de la entrega.

Fuentes de contexto: U.S. Census Bureau QuickFacts, New York city, New York (Censo 2020 e indicadores 2020–2024); New York State Department of Labor, Labor Statistics for the New York City Region (agosto 2026); College Board, 2024 New York SAT Suite of Assessments Annual Report. El reporte SAT menciona la no comparabilidad con los datos de agencias estatales y las precauciones al evaluar escuelas o distritos por puntajes.

URLs: <https://data.cityofnewyork.us/resource/uip8-fykc.json>; <https://data.cityofnewyork.us/resource/cts7-vksw.json>; <https://data.cityofnewyork.us/resource/bm4k-52h4.json>; <https://data.cityofnewyork.us/resource/f9bf-2cp4.json>; <https://www.census.gov/quickfacts/fact/table/newyorkcitynewyork/>; <https://dol.ny.gov/labor-statistics-new-york-city-region>; <https://reports.collegeboard.org/media/pdf/2024-new-york-sat-suite-of-assessments-annual-report-ADA.pdf>

Alcance de los resultados

Los números de contexto citados pertenecen a publicaciones oficiales con unidades y años identificados. Los conteos y distribuciones que genere el notebook pertenecen únicamente a los extractos descargados. No se presenta una tasa propia de arrestos, accidentes, pobreza o resultados SAT para la ciudad porque aún faltan datos completos o denominadores compatibles. Tampoco se reporta una evaluación de clúster. El siguiente hito es ejecutar, auditar y documentar el procesamiento completo antes de emitir prioridades territoriales.

Protocolo de reproducción: conservar juntos el notebook y la carpeta datos; instalar PySpark 4.x en el entorno que se use; abrir el notebook desde la carpeta entregables o desde el directorio del proyecto; ejecutar las celdas en orden; comparar los SHA-256 del manifiesto con los archivos JSON Lines; registrar versión de Spark y fecha de ejecución. El PDF SAT 2024 se cita desde la fuente oficial y no se requiere para ejecutar las consultas. Si una futura descarga devuelve un error o se actualiza la vista, se conserva la instantánea de esta entrega y se crea una versión nueva.